FX Predictions

April 30, 2024

1 FX Predictions

Creado por:

• V. D. Betancourt

1.1 Objetivo

El presente proyecto permite descargar la evolución histórica de los siguientes **Tipos de Cambio** (**Paridades**) usando la librería de Yahoo Finance ('yfinance'):

- "USDMXN"
- "EURMXN"
- "GBPMXN"
- "EURUSD"
- "GBPUSD"

Y crea un Modelo de Redes Neuronales para generar sus respectivas predicciones.

1.2 Settings

1.2.1 Entorno de Ejecución

El presente proyecto se ha ejecutado en Google Colab usando el siguiente Entorno de Ejecución:

• T4 GPU

1.2.2 Importar Librerías

```
[1]: # Importar
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.preprocessing import MinMaxScaler
from keras.models import Sequential
from keras.layers import Dense, LSTM
import yfinance as yf
```

1.2.3 Definir Paridades de Monedas

```
[2]: # Lista de paridades de monedas currency_pairs = ["USDMXN=X", "EURMXN=X", "GBPMXN=X", "EURUSD=X", "GBPUSD=X"]
```

1.2.4 Función para Descargar Datos

```
[3]: # Descargar datos históricos de las paridades de monedas
def download_data(currency_pairs):
    data = {}
    for pair in currency_pairs:
        data[pair] = yf.download(pair, start="2015-01-01", end="2024-04-30")
    return data
```

1.2.5 Función para Graficar Datos Históricos

Matplotlib

```
[4]: # Dibujar la evolución histórica de las paridades de monedas

def plot_data(data):
    for pair, df in data.items():
        plt.figure(figsize=(14,8))
        sns.lineplot(data=df['Close'])
        plt.title(f'Evolución histórica de {pair}')
        plt.show()
```

Seaborn

```
[5]: import matplotlib.pyplot as plt
     import seaborn as sns
     import pandas as pd
     import yfinance as yf
     # Función para dibujar evolución histórica de paridades de monedas
     def plot_data_sns(data, titles=None, font_scale=1.2, color='blue', figsize=(14,_
      ⇔8)):
         # Establecer el estilo de seaborn y escala de fuentes
        sns.set(style='white', font_scale=font_scale)
         # Número de subplots necesarios
        n_pairs = len(data)
        # Crear una figura con subplots
        fig, axes = plt.subplots(n_pairs, 1, figsize=figsize, squeeze=False)
        axes = axes.flatten() # Esto maneja el caso de un solo subplot
      →automáticamente
         # Iterar sobre los pares y sus respectivos DataFrames
```

```
for ax, (pair, df) in zip(axes, data.items()):
    # Trazar la línea con seaborn, enfocándose en la columna 'Close'
    sns.lineplot(data=df['Close'], ax=ax, color=color, label='Close')

# Establecer título con control para títulos personalizados
    if titles and pair in titles:
        ax.set_title(titles[pair])
    else:
        ax.set_title(f'Evolución histórica de {pair}')

# Mejora de visibilidad en los ejes
    ax.set_ylabel('Precio de Cierre')
    ax.set_xlabel('Fecha')

# Ajustar el layout para evitar superposición de elementos
    plt.tight_layout()
    plt.show()
```

1.2.6 Función para Graficar Predicciones

Matplotlib

```
[6]: # Función para visualizar las predicciones con Matplotlib
     def visualize_predictions_plt(data, models):
         for pair, model in models.items():
             df = data[pair]
             # Preprocesar los datos
             scaler = MinMaxScaler(feature range=(0,1))
             scaled_data = scaler.fit_transform(df['Close'].values.reshape(-1,1))
             # Crear conjuntos de datos de entrenamiento y prueba
             train_data = scaled_data[0:int(len(scaled_data)*0.8), :]
             test_data = scaled_data[int(len(scaled_data)*0.8):, :]
             total_dataset = np.concatenate((train_data, test_data), axis=0)
             x_{test}, y_{test} = [], []
             for i in range(60, len(test_data)):
                 x_test.append(total_dataset[i-60:i, 0])
                 y_test.append(train_data[i, 0])
             x_test, y_test = np.array(x_test), np.array(y_test)
             x_test = np.reshape(x_test, (x_test.shape[0], x_test.shape[1], 1))
             # Realizar predicciones
             predictions = model.predict(x test)
             predictions = scaler.inverse_transform(predictions)
             # Rellenar las primeras 60 entradas de las predicciones con NaN
             predictions = np.concatenate((np.full((60, 1), np.nan), predictions),
      ⊶axis=0)
```

```
# Visualizar los datos
      train = df[:int(len(scaled_data)*0.8)]
      valid = df[int(len(scaled_data)*0.8):]
      valid.insert(1, "Predictions", predictions, True)
      plt.figure(figsize=(16,8))
      plt.title(pair)
      plt.xlabel('Fecha', fontsize=18)
      plt.ylabel('Precio de Cierre', fontsize=18)
      plt.plot(train['Close'])
      plt.plot(valid[['Close', 'Predictions']])
      plt.legend(['Train', 'Val', 'Predictions'], loc='lower right')
      plt.show()
      # Exportar a CSV
      valid.to_csv('datos_fx_predicciones_plt.csv', index=False)
       # Guardar los resultados en un archivo CSV
      \#path = input("Indica la ruta donde deseas guardar el fichero en tu_{\!\!\!\perp}
⇔computadora local: ")
       #valid.to csv(path + '/' + pair + ' predictions.csv')
```

Seaborn

```
[31]: import matplotlib.pyplot as plt
      import seaborn as sns
      import numpy as np
      import pandas as pd
      from sklearn.preprocessing import MinMaxScaler
      # Función para Visualizar las Predicciones con Seaborn
      def visualize predictions_sns(data, models, train_color='#0d3160', __
       ⇔val_color='#45aab8', pred_color='#faab00'):
          for pair, model in models.items():
              df = data[pair]
              # Preprocesar los datos
              scaler = MinMaxScaler(feature_range=(0, 1))
              scaled_data = scaler.fit_transform(df['Close'].values.reshape(-1, 1))
              # Crear conjuntos de datos de entrenamiento y prueba
              train_data = scaled_data[0:int(len(scaled_data) * 0.8), :]
              test_data = scaled_data[int(len(scaled_data) * 0.8):, :]
              total_dataset = np.concatenate((train_data, test_data), axis=0)
              x_{test}, y_{test} = [], []
              for i in range(60, len(test_data)):
                  x_test.append(total_dataset[i-60:i, 0])
```

```
x_test = np.array(x_test)
      x_test = np.reshape(x_test, (x_test.shape[0], x_test.shape[1], 1))
      # Realizar predicciones
      predictions = model.predict(x_test)
      predictions = scaler.inverse_transform(predictions)
      # Rellenar las primeras 60 entradas de las predicciones con NaN
      predictions = np.concatenate((np.full((60, 1), np.nan), predictions),
⇒axis=0)
      # Visualizar los datos
      train = df[:int(len(scaled_data) * 0.8)]
      valid = df[int(len(scaled_data) * 0.8):]
      valid.insert(1, "Predictions", predictions.flatten(), True)
      # Configurar Seaborn
      sns.set(style='white')
      plt.figure(figsize=(16, 8))
      plt.title(f'Predicciones para {pair}')
      plt.xlabel('Fecha', fontsize=18)
      plt.ylabel('Precio de Cierre', fontsize=18)
      # Graficar usando Seaborn con colores personalizables
      sns.lineplot(data=train['Close'], label='Train', color=train_color)
      sns.lineplot(data=valid['Close'], label='Validation', color=val_color)
      sns.lineplot(data=valid['Predictions'], label='Prediction', __
⇔color=pred_color)
      plt.legend()
      plt.show()
      # Exportar a CSV
      valid.to_csv(f'datos_fx_predicciones_sns_{pair}.csv', index=False)
```

1.3 Modelo de Redes Neuronales

1.3.1 Definición del Modelo

```
[8]: # Crear y entrenar un modelo de red neuronal para cada paridad de monedas
def train_models(data):
    models = {}
    for pair, df in data.items():
        # Preprocesar los datos
        scaler = MinMaxScaler(feature_range=(0,1))
        scaled_data = scaler.fit_transform(df['Close'].values.reshape(-1,1))
```

```
# Crear conjuntos de datos de entrenamiento y prueba
      train_data = scaled_data[0:int(len(scaled_data)*0.8), :]
      x_train, y_train = [], []
      for i in range(60, len(train_data)):
          x_train.append(train_data[i-60:i, 0])
          y_train.append(train_data[i, 0])
      x_train, y_train = np.array(x_train), np.array(y_train)
      x_train = np.reshape(x_train, (x_train.shape[0], x_train.shape[1], 1))
      # Crear el modelo de red neuronal
      model = Sequential()
      model.add(LSTM(units=50, return_sequences=True, input_shape=(x_train.
⇔shape[1], 1)))
      model.add(LSTM(units=50, return_sequences=False))
      model.add(Dense(units=25))
      model.add(Dense(units=1))
      # Entrenar el modelo
      model.compile(optimizer='adam', loss='mean_squared_error')
      model.fit(x_train, y_train, batch_size=1, epochs=1)
      models[pair] = model
  return models
```

Α

1.3.2 Descargar Datos

```
[9]: # Descargar Datos Históricos y Guardarlos en 'data' data = download_data(currency_pairs)
```

1.3.3 Exportar CSV (Opcional)

```
[10]: import pandas as pd

# Guardar Respaldo
bk_data_fx = data.copy()

# Convertir cada valor escalar en una lista
for key in bk_data_fx:
```

```
bk_data_fx[key] = [bk_data_fx[key]]


# Convertir la copia del diccionario a DataFrame
bk_data_fx_df = pd.DataFrame(bk_data_fx)
```


[11]: # Exportar a CSV
bk_data_fx_df.to_csv('datos_fx_hist.csv', index=False)


1.3.4 Graficar Datos Históricos


Matplotlib


[12]: # Graficar Datos Históricos plot_data(data)











Seaborn

```
[33]: # Graficar Predicciones con Seaborn
      currency_pairs = ["USDMXN=X", "EURMXN=X", "GBPMXN=X", "EURUSD=X", "GBPUSD=X"]
      data = download_data(currency_pairs)
      plot_data_sns(data, font_scale=0.9, color='#0d3160')
     1 of 1 completed
          Precio de Cierre
20
15
                                          Evolución histórica de USDMXN=X
                                                                                — Close
                2015
                                           2019
                                                                       2023
                                                                              2024
                                          Evolución histórica de EURMXN=X
          Precio de Cierre
            25
            20
                2015
                       2016
                              2017
                                    2018
                                           2019
                                                         2021
                                                                2022
                                                                       2023
                                                                              2024
                                                Fecha
          o de Cierre
                                          Evolución histórica de GBPMXN=X
                2015
                       2016
                              2017
                                    2018
                                                         2021
                                                                2022
                                                                       2023
                                                                              2024
          Precio de Cierre
                                          Evolución histórica de EURUSD=X
                                                                       2023
                2015
                                    2018
                                                  2020
                                                                2022
                                                                              2024
                                                Fecha
          Precio de Cierre
1.50
                                          Evolución histórica de GBPUSD=>
                                                                                — Close
```

1.3.5 Entrenar el Modelo

2015

2017

2018

2016

```
[14]: # Entrenar el Modelo
   models = train_models(data)
   1885/1885 [============== ] - 25s 8ms/step - loss: 0.0019
                     =======] - 18s 8ms/step - loss: 0.0024
   1884/1884 [======
   =========] - 20s 9ms/step - loss: 0.0022
   1.3.6 Graficar Predicciones
```

2019

2020

2021

2022


2023

2024


Matplotlib

```
[15]: # Visualizar las Predicciones con Matplotlib
      visualize_predictions_plt(data, models)
```


14/14 [======] - 1s 7ms/step




14/14 [======] - 1s 5ms/step




14/14 [========] - 1s 5ms/step



14/14 [======] - 1s 5ms/step




14/14 [======] - 1s 5ms/step




Seaborn

[32]: # Visualizar las Predicciones con Seaborn
visualize_predictions_sns(data, models)






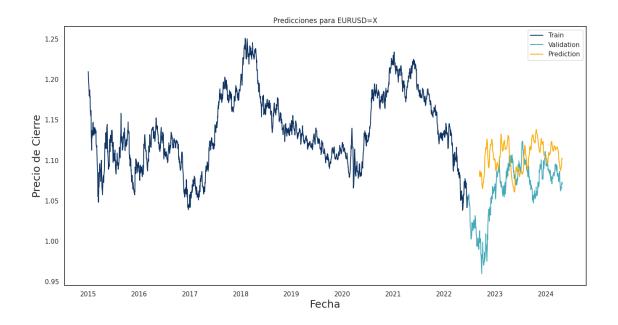
14/14 [=======] - Os 5ms/step




14/14 [======] - Os 5ms/step



14/14 [=======] - Os 5ms/step



14/14 [=======] - Os 5ms/step



1.3.7 Mostrar Tablas con Datos de Paridades y Predicciones

[30]: import pandas as pd

```
# Lista de paridades de monedas que se analizaron y para las cuales se_{f L}
 ⇔generaron predicciones
#currency_pairs = ["USDMXN=X", "EURMXN=X", "GBPMXN=X", "EURUSD=X", "GBPUSD=X"]
# Recorrer la lista de paridades y cargar cada CSV
for pair in currency pairs:
    file_name = f'datos_fx_predicciones_sns_{pair}.csv'
    df = pd.read csv(file name)
    # Mostrar el nombre del par de divisas y la información del DataFrame
    print(f'Datos para {pair}:')
    print(f'Shape del DataFrame: {df.shape}')
    print(df.head())
    print('\n' + '-'*50) # Imprime una línea separadora para cada par de
 \rightarrow divisas
Datos para USDMXN=X:
Shape del DataFrame: (487, 7)
       Open Predictions
                                               Close Adj Close Volume
                           High
                                   Low
0 20.397200
                   NaN 20.571800 20.295500 20.397200 20.397200
                   NaN 20.372700 20.218700 20.294310 20.294310
1 20.294310
                                                                    0
2 20.268499
                   NaN 20.281111 20.116301 20.268499 20.268499
                                                                    0
                   NaN 20.245119 19.997801 20.136999 20.136999
3 20.136999
                                                                    0
4 20.049500
                   NaN 20.138670 19.993200 20.049500 20.049500
_____
Datos para EURMXN=X:
Shape del DataFrame: (487, 7)
       Open Predictions
                                     Low
                                             Close Adj Close Volume
                         High
0 21.527800
                   NaN 21.5541 21.376699 21.520100 21.520100
1 21.288799
                   NaN 21.3836 21.274500 21.290199 21.290199
                                                                  0
                   NaN 21.3631 21.231199 21.321699 21.321699
2 21.323601
                   NaN 21.2533 21.099501 21.219240 21.219240
3 21.221399
4 21.194700
                   NaN 21.2103 21.020800 21.190001 21.190001
-----
Datos para GBPMXN=X:
Shape del DataFrame: (487, 7)
                            High
       Open Predictions
                                       Low
                                               Close Adj Close Volume
0 25.206200
                   NaN 25.211300 24.920481 25.197594 25.197594
1 24.810801
                   NaN 24.868225 24.755381 24.814827 24.814827
                                                                    0
                   NaN 24.879709 24.680401 24.829700 24.829700
2 24.833599
                                                                    0
3 24.713190
                   NaN 24.755768 24.548071 24.713499 24.713499
                   NaN 24.653601 24.417038 24.574400 24.574400
4 24.580700
```

Datos para EURUSD=X:

Sh	ape del Da	taFrame: (486	, 7)				
	Open	Predictions	High	Low	Close	Adj Close	Volume
0	1.049142	NaN	1.054519	1.048636	1.049142	1.049142	0
1	1.052078	NaN	1.058190	1.051425	1.052078	1.052078	0
2	1.053264	NaN	1.060288	1.047186	1.053264	1.053264	0
3	1.056412	NaN	1.058067	1.048449	1.056412	1.056412	0
4	1.052011	NaN	1.056915	1.051370	1.052011	1.052011	0
Datos para GBPUSD=X:							
Shape del DataFrame: (486, 7)							
	Open	Predictions	High	Low	Close	Adj Close	Volume
0	1.222823	NaN	1.227777	1.220063	1.222823	1.222823	0
1	1.225010	NaN	1.231922	1.224920	1.225175	1.225175	0
2	1.226407	NaN	1.231467	1.216856	1.226663	1.226663	0
3	1.225325	NaN	1.229468	1.217182	1.225085	1.225085	0
4	4 000400	37 37	1 001670	1.224350	1 006076	1 006076	0
4	1.226196	NaN	1.231679	1.224350	1.226076	1.226076	U

1.4 Fin